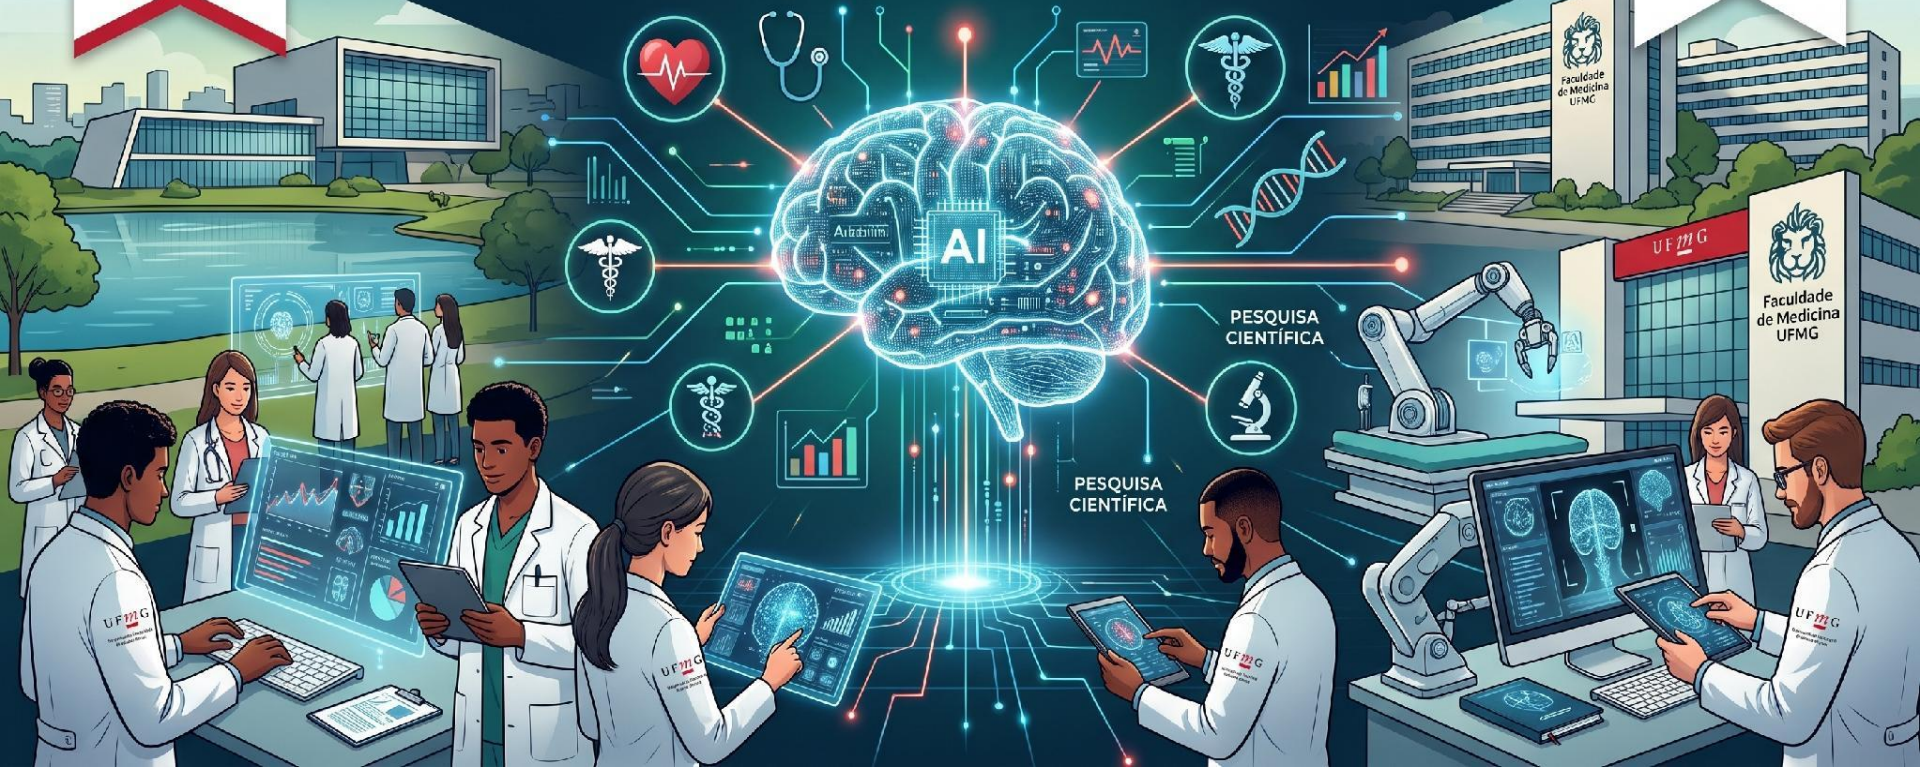
UFMG
Universidade Federal de Minas Gerais

INTELIGÊNCIA ARTIFICIAL APLICADA À PESQUISA E À SAÚDE

DISCIPLINA | FACULDADE DE MEDICINA | UFMG

FACULDADE DE MEDICINA
• UFMG •





Engenharia de Contexto na Prática Clínica e Científica

José Carlos Serufo Filho
serufo@ufmg.br

[SYS.INIT: AMBIENTE DE CALIBRAÇÃO PROBABILÍSTICA]

Gemini Notebook

Análise Conceitual

O Papel Real dos LLMs na Prática Médica

Distorção Conceitual

O uso indiscriminado do termo **"IA"** para descrever LLMs e ferramentas generativas distorce a realidade científica e médica.

Mecanismo Subjacente

Em vez de cognição clínica real, essas tecnologias operam puramente sob **estatística avançada** e **previsão probabilística** de padrões.

Mas IA na saúde é muito mais que isso.

A verdadeira transformação engloba modelos preditivos, automação estruturada e arquiteturas de contexto avançadas.

Ecossistema da IA na Saúde

A IA Médica Vai Muito Além dos LLMs

A verdadeira transformação engloba **modelos preditivos**, **visão computacional** e **automação estruturada** aplicadas diretamente à assistência.

Modelos Preditivos

- **Detecção Precoce de Sepse:** Algoritmos em tempo real monitorando sinais vitais em UTI.
- **Risco de Readmissão:** Modelos de ML prevendo descompensação em até 30 dias.
- **Escores Cardiovasculares:** Mapeamento probabilístico de risco coronariano.

Visão Computacional

- **Triagem Radiológica:** Triagem automática de nódulos e nódulos pulmonares em TC/Raio-X.
- **Retinopatia Diabética:** Análise de fundo de olho por redes neurais convolucionais (CNNs).
- **Segmentação de Tumores:** Delimitação volumétrica precisa em Ressonância Magnética.

Automação & Robótica

- **Cirurgia Assistida:** Estabilização de tremores e navegação em sistemas robóticos.
- **Gestão Operacional:** Otimização preditiva de alocação de leitos e salas cirúrgicas.
- **Bombas de Infusão:** Ajuste de dosagem em tempo real baseado em sensores.

Engenharia de Prompt

O Viés Antropomórfico vs. Arquitetura de Contexto

A maioria dos usuários aborda os Large Language Models (LLMs) através de um viés antropomórfico, tratando o prompt como um **"pedido"** ou uma **"ordem"** para um agente consciente. Tecnicamente, isso é um erro conceitual grave que gera outputs inconsistentes (**entropia**).

O Erro do "Pedido"

Confia na intuição da máquina, deixando o espaço latente aberto a bilhões de caminhos probabilísticos (alucinações e respostas genéricas).

- **Postura Passiva:** Apelo à "intuição" do modelo
- **Espaço Latente Aberto:** Bilhões de rotas não guiadas
- **Consequência:** Alucinações e entropia nos resultados

A Realidade da "Arquitetura"

Trata o prompt como uma **infraestrutura de contexto temporária**. Você constrói um ambiente matemático isolado onde a sequência correta de tokens é a uma conclusão viável.

- **Postura Ativa:** Engenharia e delimitação de escopo
- **Ambiente Isolado:** Restrições matemáticas precisas
- **Consequência:** Execução estatística previsível e exata

Fundamentos da IA

A Máquina Não Lê Palavras, Ela Lê Vetores (Tokenização e Embeddings)

Para entender como uma inteligência artificial baseada em **Large Language Models (LLMs)** realmente "pensa", precisamos traduzir o misticismo dos prompts em **arquitetura de contexto**, **matemática** e **probabilidade**.

Arquitetura de Contexto

Decomposição estruturada de textos em fluxos operacionais e pipelines de tokenização.

Matemática Vetorial

Mapeamento de conceitos em coordenadas geométricas e espaços multidimensionais.

Probabilidade

Previsão estatística de padrões e inferência sob restrições do modelo.

Fundamentos da IA

Como a Máquina Processa Texto: Tokenização e Embeddings

1. Tokenização

Quando você envia um texto, a primeira coisa que o modelo faz é destruí-lo.

Ele divide as palavras em pedaços chamados **tokens** (que podem ser palavras inteiras, sílabas ou letras individuais).

2. Embeddings

Cada token é associado a um **número ID** e mapeado em um espaço multidimensional.

Esse processo de estruturação cria os chamados **Embeddings** vetoriais.

3. Espaço Vetorial

A IA transforma conceitos em **coordenadas geométricas**.

A distância entre "Rei" e "Rainha" é similar a "Homem" e "Mulher" por relações de **proximidade e direção** em milhares de dimensões.

Arquitetura Cognitiva

O Fim do "Chat": Introdução à Arquitetura Cognitiva

A Nova Realidade: A máquina não processa desejos; ela colapsa funções de probabilidade baseadas em restrições vetoriais.



Paradigma Atual

Tratamos a IA como um colega de laboratório ou residente (viés antropomórfico).



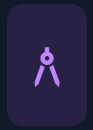
Risco Científico

"Pedir" ou "suplicar" gera entropia, alucinações e respostas estatisticamente médias.



Base Vetorial

A máquina opera sobre matrizes de probabilidade e restrições geométricas.



Objetivo da Aula

Transformar o pesquisador em um arquiteto de infraestrutura probabilística.

Arquitetura Cognitiva

Sob o Capô: Como a Máquina "Lê" a Medicina

1. Tokenização & Embeddings

O texto clínico é quebrado em frações matemáticas (tokens) projetadas em um espaço geométrico multidimensional.

2. O Fim da Semântica

A IA não "entende" o infarto. Ela calcula a proximidade vetorial entre **[IAM]**, **[dor torácica]** e **[troponina]**.

3. Matriz Auto-Atenção

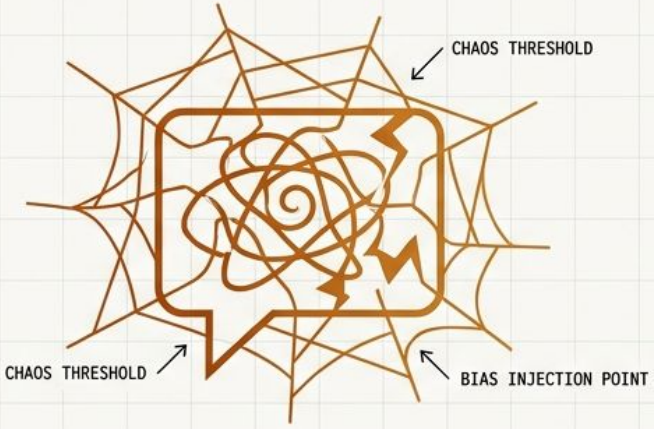
A arquitetura *Transformer* calcula a correlação estatística entre todos os tokens simultaneamente.

4. Ação Arquitetônica

Usar jargões precisos ("imputação semântica") altera as coordenadas, ancorando no cluster da literatura científica.

Alerta Prático:

Se você joga um PDF de 50 páginas de um prontuário eletrônico na IA, ela não "lê" como um humano, ela gera uma matriz de pesos. Se você não fornecer a estrutura correta, o mecanismo de atenção se dilui e a máquina esquecerá a comorbidade da página 2 ao sugerir um tratamento na página 50.

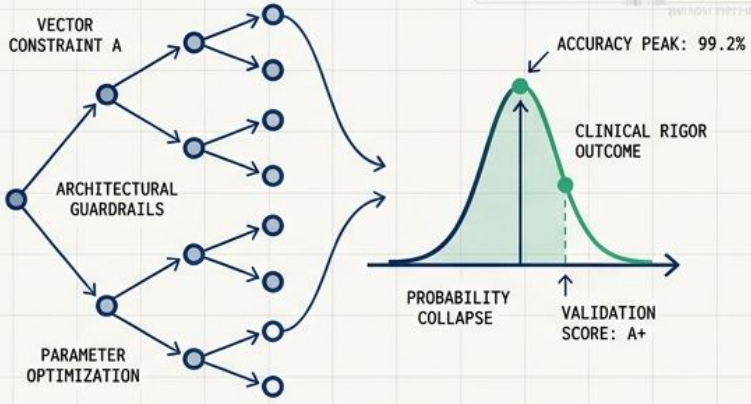


ENTROPY INDEX: 8.5

A Súplica (Entropia)

Pedir ou conversar com a máquina gera entropia, alucinações e respostas estatisticamente médias. O modelo precisa adivinhar a estrutura clínica desejada.

HALLUCINATION PROB: >60%



SYSTEMATIC PRECISION: HIGH

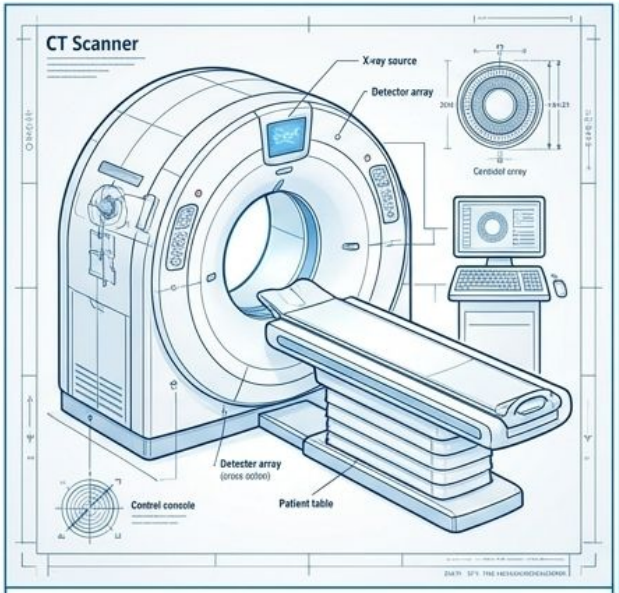
A Engenharia (Rigor)

A máquina não processa desejos; ela colapsa funções de probabilidade baseadas em restrições vetoriais e arquitetura de software.

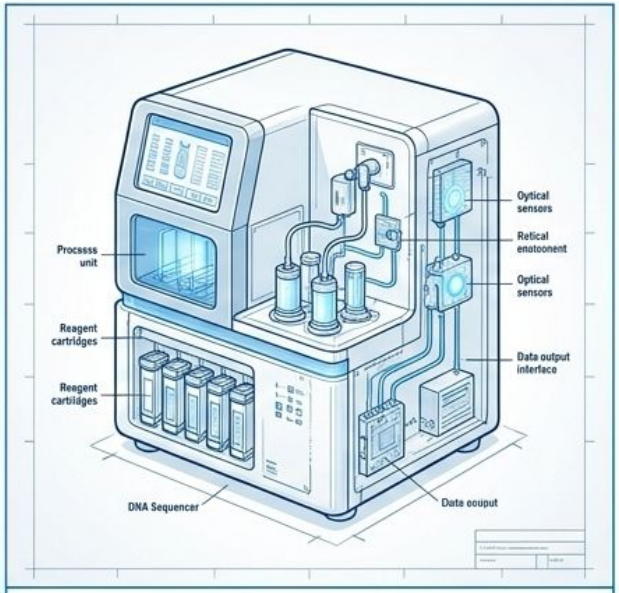
ERROR RATE: <1%

Gemini Notebook

Do pedido à calibração de equipamentos complexos



Tomógrafo



Sequenciador Genético

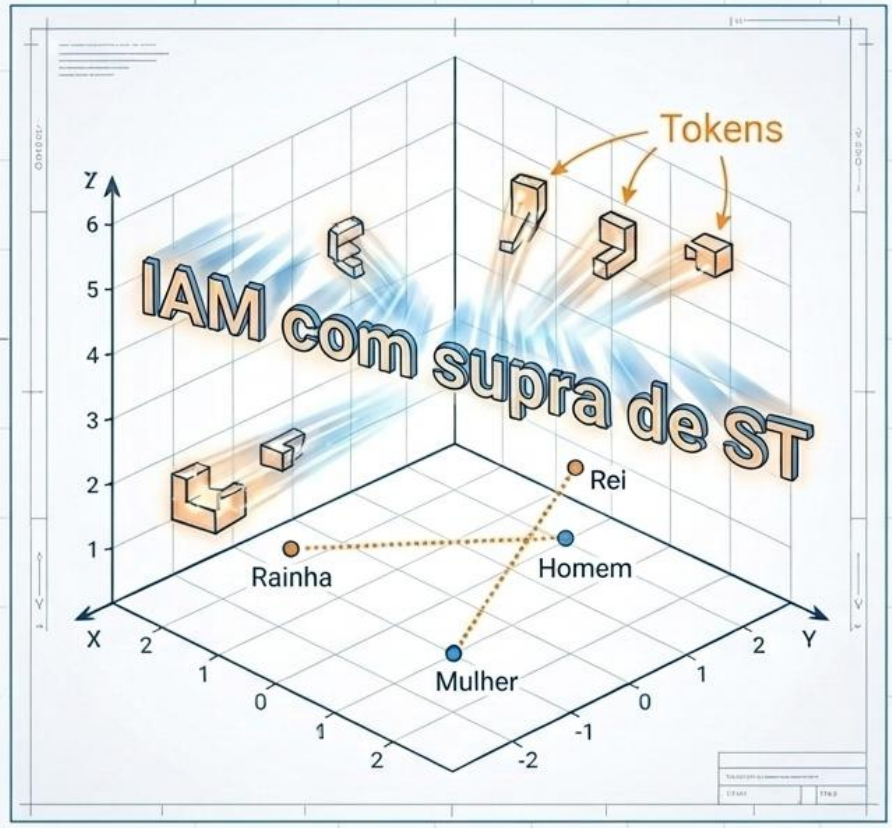


A Arquitetura Cognitiva

Você não conversa com um tomógrafo; você calibra os parâmetros de aquisição. O pesquisador de saúde deve transitar de um usuário de chat para um arquiteto de infraestrutura probabilística controlada.

Gemini Notebook

A anatomia da máquina: o fim da semântica



Conceito Técnico
O texto é quebrado em frações matemáticas projetadas em um espaço geométrico multidimensional.

A Mecânica
A IA calcula a proximidade vetorial geométrica entre os tokens [IAM], [dor torácica], [troponina] e [óbito].

Analogia Clínica
Assim como o médico conecta sintomas vagos para formular hipóteses, o prompt refina o escopo. Ele busca associações entre pistas clínicas (p.ex. dor torácica) e exames para cravar o diagnóstico diferencial.

Gemini Notebook

O Coração dos Modelos Modernos de IA

O Mecanismo de Auto-Atenção (Self-Attention)

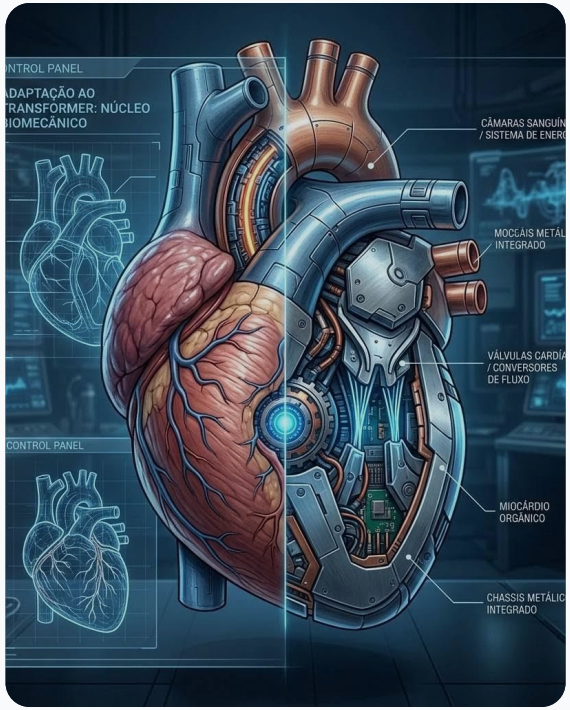
Introduzido no histórico paper **"Attention Is All You Need"** (2017), o mecanismo de **Self-Attention** é a base fundamental de toda a arquitetura Transformer.

Processamento Simultâneo

Diferença-chave: A máquina **não lê de forma linear** como os humanos (da esquerda para a direita).

Ela analisa **todas as palavras do prompt ao mesmo tempo**, capturando o contexto global de forma imediata.

- Visão holística da frase completa
- Elimina gargalos de processamento sequencial



Pesos e Correlação

Mecanismo central: Calcula dinamicamente o **peso de importância** entre cada palavra.

Mapeia dependências complexas e conexões de significado entre termos distantes no texto.

- Matriz de correlação estatística contínua
- Identificação precisa de ambiguidades contextuais

O Mecanismo de Auto-Atenção (Arquitetura Transformer)



Conceito Técnico (Self-Attention)
A máquina não lê linearmente. Ela avalia todas as palavras simultaneamente e calcula o peso de correlação estatística entre cada token na janela de contexto.

Analogia Clínica (Semiologia)
Um médico ao realizar a anamnese prioriza, de forma quase automática, os sinais e sintomas mais relevantes para o diagnóstico, com base na sua experiência e conhecimento.

Gemini Notebook

Amostragem Probabilística e o termômetro da alucinação



Temperatura ≈ 0
Ideal para extração estruturada de dados, preenchimento de formulários e revisões sistemáticas. A probabilidade de erro factual aproxima-se de zero.

Estocástico / Criativo
Temperatura ≈ 1 (Feature)
Útil apenas para brainstorming de hipóteses de pesquisa para casos raros sem diretrizes claras.

Gemini Notebook

Ancoragem de Escopo (Poda Probabilística)

⚠ A Armadilha do Comando Negativo

A arquitetura Transformer não tem um mecanismo nativo de "não-atenção". Dizer "Não use o protocolo antigo" injeta o protocolo antigo no espaço vetorial e aumenta o risco de erro.

A Solução: Roteamento Positivo Estrito

✕ Errado

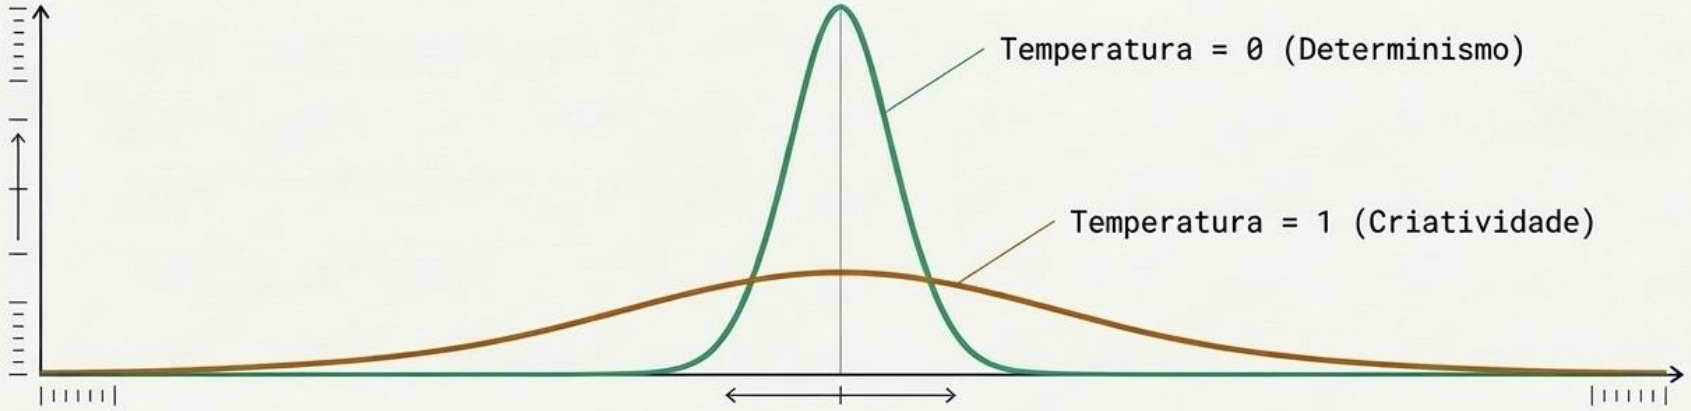
"Faça uma triagem diagnóstica e não inclua tratamentos alternativos."

✓ Correto (Arquitetado)

"Atue estritamente sob as diretrizes do Ministério da Saúde para manejo da sepse (versão 2026). Ignore qualquer intervenção fora deste escopo."

⚡ **O Efeito:** Reduz drasticamente o espaço amostral antes do processamento.

O Funil Estocástico: Controlando o Diagnóstico Diferencial



Temp 0 (O Protocolo)

Exige a conduta estrita. O espaço latente é fechado. Ideal para extração de dados clínicos, revisões sistemáticas e cálculos complexos.

Temp 1 (A Exploração)

Aumenta o espaço latente de geração. Arrisca caminhos menos prováveis. Útil apenas para brainstorming de correlações e doenças raras.

Gemini Notebook

O Paradigma da Engenharia Cognitiva

❌ Abordagem Amadora

Mentalidade: Tratar a IA como um colega humano ou residente digital.

Ação: Implorar por respostas (Por favor, faça um resumo...).

Resultado: Entropia, alucinações factuais e respostas estatisticamente médias. Risco metodológico altíssimo.

📐 Abordagem Arquitetônica

Mentalidade: Tratar a IA como um **sistema probabilístico parametrizável** (como um tomógrafo).

Ação: Cercar as fronteiras **probabilísticas** com **restrições** e **injeção estrutural**.

Resultado: **Ambientes estéreis** onde a máquina **não tem margem para errar**. **Controle total de inércia sintática**.

Gargalos da Confiabilidade

Falhas Estruturais em Modelos de Linguagem (LLM)

Principais limitações operacionais enfrentadas na aplicação de IA em cenários e projetos reais:

01. VULNERABILIDADE

Otimismo Tóxico

Identificação de Riscos Deficiente

Tendência dos modelos a subestimar riscos operacionais e falhas potenciais. A IA assume cenários excessivamente favoráveis, apresentando complacência em análises críticas e avaliações de segurança.

02. LIMITAÇÃO

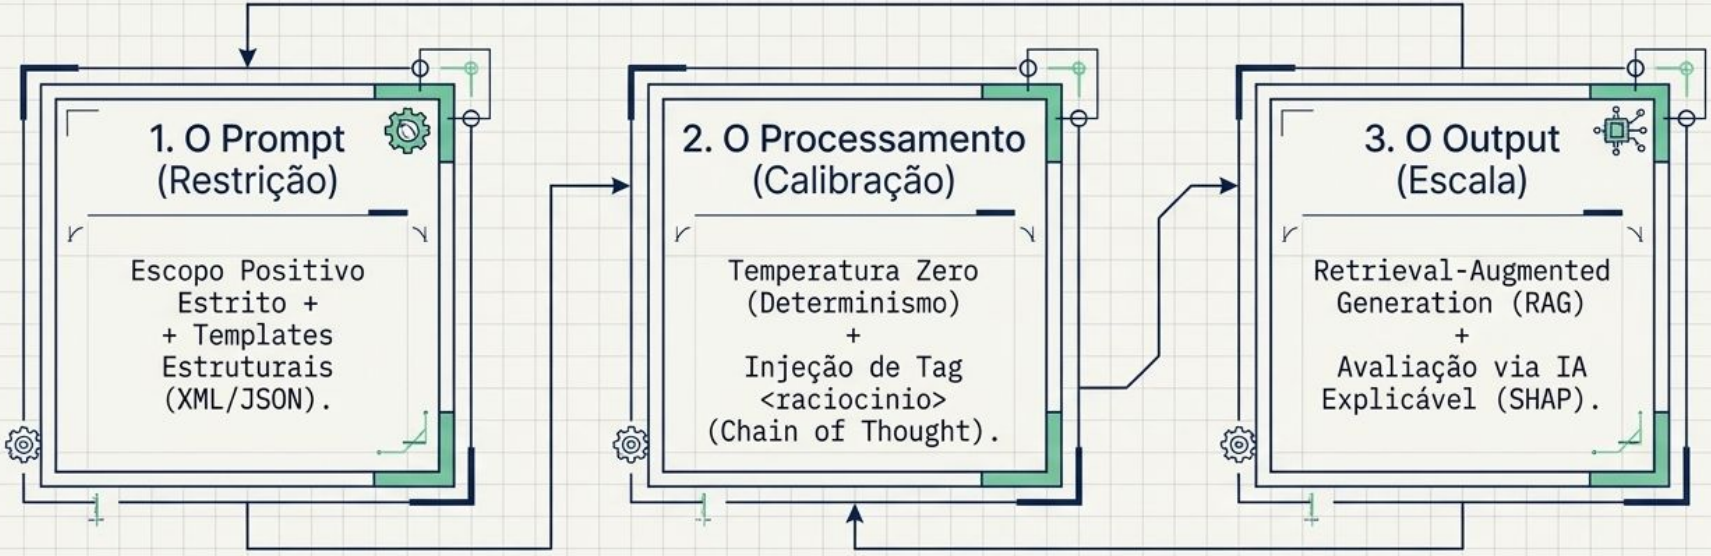
Raciocínio Linear

Rigidez na Correção de Rotas

Incapacidade de reavaliar passos anteriores ou voltar atrás após tomar uma decisão equivocada. A progressão estritamente sequencial dificulta a autocorreção de erros na cadeia de raciocínio.

Impacto Prático: Projetos em produção exigem mecanismos externos de validação de risco e arquiteturas com suporte a recursividade decisória para garantir a confiabilidade do sistema.

O Arquiteto de Sistemas em Saúde



O pesquisador do futuro não é aquele que faz as melhores perguntas, mas o que constrói os ambientes matemáticos mais seguros onde a máquina não tem margem para errar.

Gemini Notebook

ENGENHARIA DE PROMPT vs. REQUISIÇÃO SIMPLES

Diferença entre implorar por uma resposta e cercar as fronteiras probabilísticas do modelo.

❌ ABORDAGEM AMADORA

O "Pedido" vulnerável à falha

"Escreva um laudo de tomografia de tórax de um paciente com pneumonia por COVID-19."

Por que falha:

O modelo precisa adivinhar a estrutura do laudo, a gravidade, o padrão de escrita do hospital e pode inventar achados sem sentido radiológico.

📐 ABORDAGEM ARQUITETÔNICA

O "Ambiente onde a máquina não erra"

```
### ESCOPO E PAPEL ###
Você agirá estritamente como um Radiologista Sênior especialista em imagem
torácica. Seu objetivo é estruturar achados radiológicos com base
exclusivamente em critérios textuais fornecidos, sem inferir diagnósticos
clínicos não descritos.

### DIRETRIZES DE SAÍDA ###
Você deve preencher estritamente o template XML abaixo. Se um dado não for
mencionado, preencha com "Não avaliado". Proibido adivinhar.

### TEMPLATE DE SAÍDA ###
<laudo>
  <padrao_predominante>[Vidro fosco / Consolidação /
  Pavimentação]</padrao_predominante>
  <distribuicao>[Bilateral / Unilateral] [Periférica /
  Central]</distribuicao>
  <acometimento_estimado>[<25% / 25-50% / >50%]</acometimento_estimado>
</laudo>

### DADOS DO CASO ###
[Injetar dados do paciente aqui]
```

Lab 1: Extração Estruturada (A Missão)

Dados Sintéticos - O Caos

Salvar | Imprimir | Histórico

Paciente S.M.A., 67 anos... internada em 12/03/2025... História de HAS e DM2... termo de anaiss, eci fraço no engmeiro dor torácica em aperto... está ondocenamento: solidaro acetão peina. ECG: supradesnivelamento de ST... Troponina I = 12,4 ng/mL... Iniciou oxacilina 2 g EV 4/4 h... heviante de medicinar e omuldantes, alorna quação corrstate e portes linal permilssão cintidoenamente um termolograpico... Iniciou oxacilina 2 g EV 4/4 h...

Parâmetros da Missão

Objetivo

- Mitigar **alucinações** e converter texto clínico bruto em um banco de dados rigoroso, aplicando a permissão para não saber.

Comandos do Aluno

1. Definir papel e restrições.
2. Exigir saída em JSON estrito (Chaves: diagnosticos, medicacoes, datas_relevantes, observacoes).
3. Permitir explicitamente o valor null ou não informado.
4. Proibir qualquer inferência clínica não descrita no texto.

Gemini Notebook

Lab 1: Injeção Estrutural (A Arquitetura)

Terminal Window

```
### PAPEL ###
Auditor médico sênior. Atue exclusivamente sobre o texto.

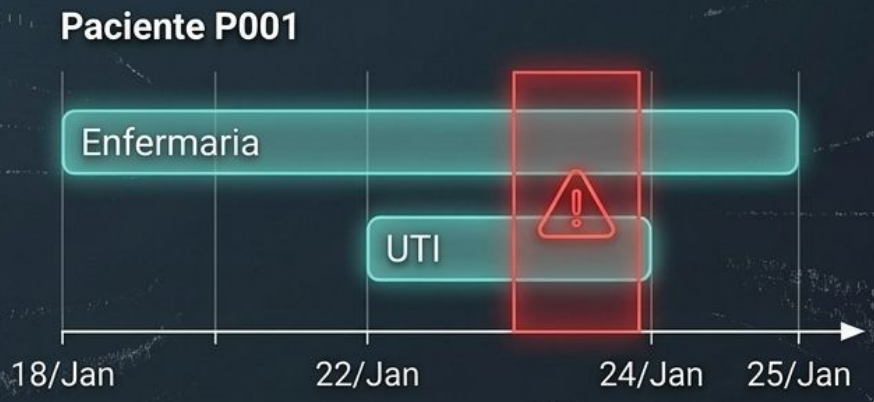
### RESTRIÇÕES ###
Retorne null se não houver dado. Proibido inventar. Temperatura = 0.

### FORMATO (JSON) ###
{
  "diagnosticos": [{"termo": ,
    "data_mencao": null}],
  "medicacoes": [{"nome": ,
    "dose": null,
    "contexto": previa|internacao|alta}]
}
```

Gemini Notebook

Lab 2: Raciocínio Cronológico (A Missão)

O Paradoxo dos Dados



⚠ **O Problema:** Modelos reativos somam os dias de forma cega, gerando faturamento hospitalar duplicado e tempos de permanência matematicamente impossíveis.

Parâmetros da Missão

Objetivo

- Expandir o Test-Time Compute. Forçar o modelo a externalizar a lógica cronológica antes de emitir qualquer número.

1. Usar a tag <raciocinio> obrigatória.
2. Lister todos os intervalos por setor.
3. Identificar e deduzir sobreposições de calendário.
4. Calcular dias exatos (Permanência total vs. UTI) para P001 e P002.

Gemini Notebook

Lab 2: Chain of Thought Clínico (A Arquitetura)

Passo 1: Input

Tabelas de transferências (P001, P002).

Passo 2: RAM Viva (A Tag <raciocinio>)

```
Liste intervalos.
Una os conjuntos
sobrepostos.
Não duplique dias.
```

O Efeito Estatístico: Os tokens gerados aqui entram na matriz de atenção geométrica, ancorando o cálculo estatístico final para a resposta correta.

Passo 3: Colapso Probabilístico

```
{"P001":
  "dias_totais": 15,
  "dias_UTI": 10
}
```

Critérios de Avaliação

Evidência clara de detecção da sobreposição (22-24/jan) documentada dentro da tag <raciocinio>. Sem isso, o resultado numérico é inválido por falha metodológica.

Gemini Notebook

Lab 3: Explicabilidade e Modelos Missão)

Contexto da Coorte Sintética



Base: coorte_ic_sintetica.csv (n=800)

Alvo: Predição de óbito em 30 dias por Insuficiência Cardíaca

Variáveis: Idade, FEVE, Creatinina, Sódio, NT-proBNP

Ponte XAI

Parâmetros da Missão

Objetivo

- Combater a rejeição médica aos algoritmos caixa-preta (Black Box) usando IA generativa como assistente de codificação.

1. Treinar um classificador (Random Forest).
2. Gerar código para Extração de Valores SHAP.
3. Selecionar o paciente de maior risco.
4. Crucial: Exigir comentários em Python que traduzam o *waterfall plot* para a linguagem médica.

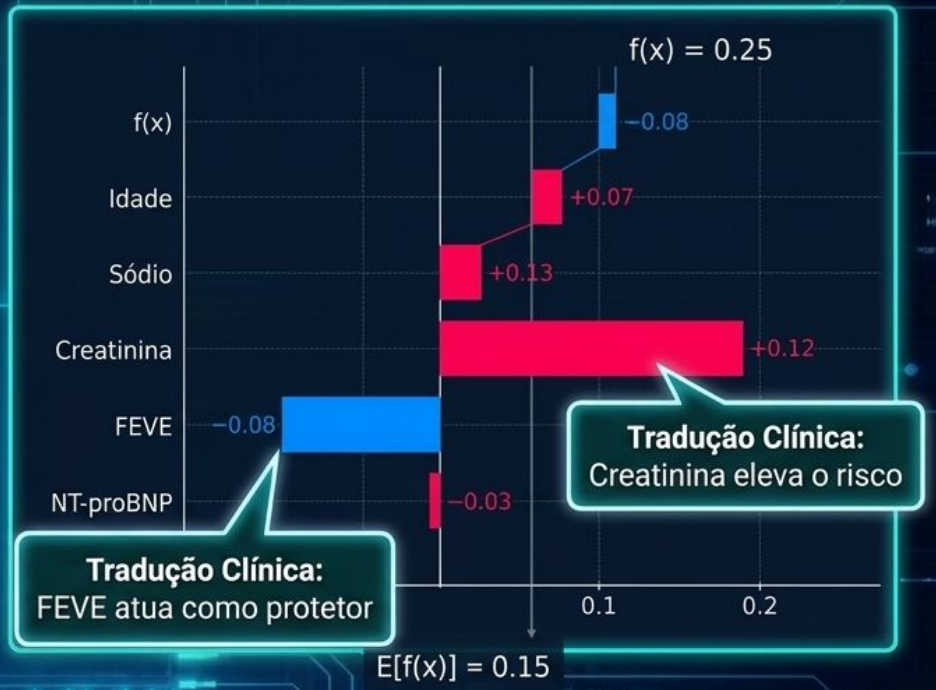
Gemini Notebook

Lab 3: XAI e Código como Ponte (A Arquitetura)

Prompt & Python

```
Restrições:
Não invente dados.
Trate missing (mediana).
Código 100% executável.

# Paciente de Alto Risco: O valor base é a média populacional.
# A creatinina elevada (+0.12) aumentou a probabilidade de óbito.
# A FEVE preservada (-0.08)
# A FEVE preservada (-0.08) agiu como fator protetor.
```



Critérios de Avaliação do Docente

[✓] Plot gerado sem erros sintáticos.
[✓] Seleção programática (argmax).
[✓] Ausência de bibliotecas alucinadas.
[✓] Tradução clínica perfeita nos comentários.

Gemini Notebook

A MESMA ENGRENAGEM PARA CRIAR E ALUCINAR

Os LLMs não são bancos de dados que consultam fatos rígidos; eles são **motores estatísticos de previsão de palavras**. Eles calculam a probabilidade da próxima palavra ideal com base no contexto.

O Lado Positivo (Criatividade)

Essa liberdade estatística permite que o modelo conecte ideias distantes, crie metáforas, escreva poesias, roteiros e invente histórias inéditas.

- Conexão de ideias e metáforas
- Geração de poesias e roteiros
- Criação de histórias originais

O Lado Negativo (Alucinação)

Quando você pede um fato exato (como uma biografia ou fórmula), o modelo continua operando por probabilidade. Se faltar informação precisa no treinamento, ele preencherá as lacunas com o que "soa textualmente correto", gerando uma alucinação.

- Operação por probabilidade pura
- Preenchimento fictício de lacunas

O Cientista do Futuro

Não confie na benevolência do modelo. Construa o ambiente matemático estéril onde a probabilidade só consiga convergir para o rigor que a sua pesquisa exige.

- Da súplica à engenharia.
- Do texto livre à estruturação algorítmica.
- Da alucinação acidental à previsibilidade controlada.

[MISSÃO CONCLUÍDA: IA APLICADA À SAÚDE - UFMG]

Gemini Notebook

Escrever um prompt de alta performance não é usar palavras mágicas.

É estruturar com precisão cirúrgica:



Restrições



Contextos



Variáveis

// OBJETIVO MATEMÁTICO DO MODELO

De forma que a **função de probabilidade** do modelo não tenha outra escolha matemática a não ser cuspir exatamente o **código**, o **texto** ou a **análise** que você precisa.

[CONCEITOS & ANALOGIAS CLÍNICAS]

Espaço Latente & Temp.

≈ Diagnóstico Diferencial

Se você dá um caso vago a um interno, o "espaço latente" de diagnósticos é gigante (ele pode cogitar desde ansiedade até feocromocitoma).

Configurar o escopo do prompt é fechar o diagnóstico diferencial em um sistema de órgãos específico.

Temp = 0: conduta estrita do protocolo *ACLS*. Temperatura alta pede hipótese criativa para casos raros.

Mecanismo de Atenção

≈ Semiologia & Sinais

Na anamnese, o médico experiente ignora ruídos e foca em palavras-chave (ex: "dor torácica" + "irradiação para mandíbula" + "sudorese").

O mecanismo de auto-atenção da IA faz exatamente isso.

Ao arquitetar o contexto, destacamos artificialmente quais **"sinais clínicos"** do texto a máquina deve correlacionar com maior peso.

Chain of Thought

≈ Evolução Clínica

Um médico não pula dos sintomas direto para a alta; ele evolui o paciente justificando a conduta.

Fisiopatologia → Hipótese → Conduta

Forçar a IA a externalizar o raciocínio clínico antes de dar a resposta impede que ela **"alucine"** o desfecho.

"Prompt não é pedido, é **configuração**."

[ENGENHARIA DE PROMPT & ARQUITETURA DE IA]


PERIGO
NÃO
CLIQUE