INTELIGÊNCIA ARTIFICIAL APLICADA À PESQUISA E À SAÚDE

Disciplina / Workshop intensivo (4 horas)

Material base reestruturado para pós-graduação

Faculdade de Medicina da Universidade Federal de Minas Gerais
Programa de Pós-Graduação (Mestrado e Doutorado)

Engenharia Cognitiva e uso rigoroso de Large Language Models em pesquisa clínica e saúde

Objetivo: capacitar pesquisadores e profissionais de saúde a transitar do uso casual de ferramentas generativas para a aplicação metodologicamente rigorosa da Inteligência Artificial, com controle de erros, reprodutibilidade e segurança.

1. Premissa fundamental

Os modelos de linguagem atuais **não "entendem" medicina**. Eles operam por estatística avançada e previsão probabilística de padrões de dados. Tratar a Inteligência Artificial como um "colega de plantão" ou "residente digital" introduz vieses, alucinações e risco metodológico que podem comprometer uma coorte inteira ou a validade de um estudo.

O pesquisador precisa aprender a **configurar o ambiente probabilístico** da máquina da mesma forma que calibra um tomógrafo, um sequenciador genético ou um protocolo de ensaio clínico. O objetivo desta disciplina é transformar o médico/pesquisador de um "usuário de chat" em um arquiteto de infraestrutura probabilística controlada.

2. Estrutura da disciplina (4 blocos de 1 hora)

Bloco 1 — A IA como motor analítico e os limites da atenção

Objetivo de aprendizagem

Desconstruir a visão de "chatbot" e apresentar o modelo de linguagem como um sistema probabilístico parametrizável, com ênfase nos riscos de aplicação em saúde sem os devidos controles (guardrails).

Conteúdo teórico

- Prompt não é pedido: é configuração de Persona, Contexto, Restrições e Objetivos (Arquitetura Cognitiva).
- O efeito *Lost in the Middle*: por que a IA erra ao processar prontuários longos ou PDFs extensos de artigos (diluição do mecanismo de atenção no meio do texto).
- Modelos reativos versus modelos de raciocínio: quando usar cada um na triagem de dados, extração de entidades clínicas e revisões sistemáticas de literatura.

Prática (15 min)

> *Os alunos recebem um texto bruto de evolução clínica não estruturada.* ***Missão:*** *construir um prompt de Arquitetura Cognitiva que force a IA a atuar como auditor médico, extraindo diagnósticos, medicações e datas em formato JSON estrito, com permissão explícita para "não saber" (mitigação de alucinação).*

Bloco 2 — Raciocínio clínico e Chain of Thought

Objetivo de aprendizagem

Ensinar a forçar o modelo a externalizar a lógica antes de emitir um parecer — fundamental para cálculos de dosagem, tempo de internação, interações medicamentosas e análise de sobreposições temporais.

Conteúdo teórico

- Mecânica do *Chain of Thought* (CoT): o espaço de geração de tokens atua como "memória de rascunho" para deduções complexas.
- Falhas catastróficas da IA em lógicas de faturamento hospitalar e contagem de dias de UTI — e como a estruturação em etapas resolve o problema.
- Ciclo de vida do contexto: como evitar degradação em conversas longas (ex.: construção de artigo científico) por meio de técnicas de *state-tracking*.

Prática (15 min)

> *Análise de uma coorte sintética com datas de internação sobrepostas e transferências de setor.* ***Missão:*** *construir prompt com a tag <raciocinio> que obrigue o modelo a mapear as sobreposições cronológicas e calcular o tempo total exato de permanência antes da resposta final.*

Bloco 3 — Desafios tabulares: imputação de dados e explicabilidade

Objetivo de aprendizagem

Transitar do texto livre (LLMs) para dados estruturados (Machine Learning clássico), enfrentando os principais problemas da pesquisa em saúde no mundo real: *missing data* e a “caixa-preta” dos modelos preditivos.

Conteúdo teórico

- Realidade dos dados clínicos: *missing data* em prontuários eletrônicos (DataSUS, bases de operadoras).
- Imputação semântica versus estatística básica: por que preencher valores ausentes com a média destrói a validade da pesquisa.
- *Explainable AI* (XAI): introdução prática à interpretação de valores SHAP (SHapley Additive exPlanations) em modelos preditivos oncológicos ou de desfecho.

Prática (15 min)

Uso de um LLM como assistente de codificação. ***Missão:*** *estruturar prompt para que a IA escreva um script em Python focado na avaliação de importância de variáveis (Feature Importance) de um classificador clínico com a biblioteca SHAP, exigindo comentários sobre como interpretar o waterfall plot para a tomada de decisão médica.*

Bloco 4 — RAG, SQL clínico e automação de pesquisa

Objetivo de aprendizagem

Escalar a capacidade analítica: tirar o modelo do “vácuo” e conectá-lo a bases de dados reais e à literatura acadêmica, garantindo ancoragem factual.

Conteúdo teórico

- *Retrieval-Augmented Generation* (RAG): como ancorar o modelo exclusivamente em guidelines médicos ou papers específicos (evitando que a IA “invente” protocolos).
- Conversão de perguntas de pesquisa em linguagem natural para queries SQL complexas (ex.: AWS Athena).
- LLM-as-a-Judge: uso de modelos de alta capacidade para avaliar, de forma automatizada e em escala, o rigor e a toxicidade de saídas geradas por outros algoritmos.

Prática (15 min)

Engenharia de prompt para análise de grandes bases de saúde. ***Missão:*** *desenvolver requisição em que a IA atue como Arquiteto de Dados Clínicos. O aluno fornece o schema de duas tabelas (Pacientes e Utilização) e a IA deve gerar uma query SQL robusta que relacione custos e desfechos, explicando a lógica das funções de janela na seção de raciocínio.*

3. Fundamentos técnicos traduzidos para a lógica médica

3.1 Como a máquina realmente "pensa"

1. Tokenização e Embeddings
A IA não lê palavras. Ela transforma o texto em vetores numéricos em um espaço de milhares de dimensões. Conceitos próximos (ex.: "IAM", "dor torácica", "troponina") ficam geometricamente próximos. *Analogia clínica:* semelhante a um mapa de redes de associação diagnóstica construído a partir de coocorrências.

2. Mecanismo de Atenção (arquitetura Transformer)
A máquina olha para **todas** as palavras do prompt ao mesmo tempo e calcula o peso de correlação entre elas. *Analogia clínica:* a semiologia experiente — o médico foca nos sinais de alerta ("dor torácica + irradiação para mandíbula + sudorese") e ignora o ruído do restante da anamnese.

3. Próxima palavra mais provável (amostragem probabilística)
O modelo não "sabe" fatos. Ele calcula a probabilidade do próximo token dado o histórico. A temperatura controla o determinismo:
• Temperatura próxima de 0 → determinismo (ideal para extração de dados, cálculos, revisões sistemáticas, preenchimento de REDCap).
• Temperatura próxima de 1 → maior aleatoriedade / risco de alucinação (útil apenas para brainstorming de hipóteses de pesquisa).

4. Por que o "pense passo a passo" funciona
Cada token gerado entra na janela de contexto e influencia o próximo. Forçar a externalização do raciocínio (*Chain of Thought*) funciona como uma evolução clínica raciocinada: impede que o modelo "pule" da queixa para a alta sem justificativa intermediária, guiando a probabilidade para o desfecho correto.

3.2 Arquitetura Cognitiva versus "pedido"

A diferença entre implorar por uma resposta e cercar as fronteiras probabilísticas do modelo determina a qualidade e a segurança do resultado.

Abordagem amadora (vulnerável)	Abordagem arquitetônica (controle)
"Escreva um laudo de TC de tórax de um paciente com pneumonia por COVID-19."	Definição clara de papel (Radiologista sênior), restrições ("não inferir diagnósticos não descritos"), template de saída obrigatório (XML/JSON) e permissão explícita para "Não avaliado" quando o dado não existir.
O modelo adivinha estrutura, gravidade e padrão de escrita; pode inventar achados radiológicos.	O espaço amostral é drasticamente reduzido. A probabilidade de erro estrutural e factual se aproxima de zero.

A alucinação **não é um bug isolado**: é o mesmo mecanismo estatístico que permite criatividade e flexibilidade. Em pesquisa clínica, o objetivo é cercar as fronteiras probabilísticas do modelo para que a probabilidade de erro factual se aproxime de zero, preservando a utilidade generativa apenas quando desejada (ex.: geração de hipóteses).

4. Três pilares da Engenharia de Contexto em Saúde

Pilar 1 — Ancoragem de Escopo (poda probabilística)

Evitar comandos negativos (“não use o protocolo antigo”), pois a arquitetura Transformer não possui mecanismo nativo de “não-atenção” e a menção injeta o conceito indesejado no espaço vetorial. Preferir roteamento positivo estrito: “Atue exclusivamente sob as diretrizes do Ministério da Saúde para manejo da sepse (versão vigente). Ignore qualquer intervenção fora deste escopo.” Isso reduz drasticamente o espaço amostral antes do processamento.

Pilar 2 — Injeção estrutural (sintaxe e inércia)

Fornecer exemplos de entrada/saída perfeitos (*few-shot prompting*), delimitadores rígidos (<paciente>, ### HISTÓRICO) e exigência de saída tipada (JSON, XML ou CSV) cria uma “bacia de atração geométrica” contra alucinações de formato. Quando a saída precisa ser injetada em pipelines de Machine Learning ou em plataformas como AWS Athena, a previsibilidade sintática é mandatória.

Pilar 3 — Direcionamento lógico (Chain of Thought clínico)

Obrigar a externalização de passos lógicos antes da conclusão final, simulando uma discussão de caso ou comitê de ética. Exemplo: em vez de “Qual a predição de risco deste paciente?”, usar “Antes de emitir o escore final, abra a tag <raciocinio>. Analise os dados laboratoriais e mapeie a importância de cada variável clínica. Avalie como um gráfico de contribuição (valores SHAP) explicaria o peso da creatinina neste desfecho. Somente após esta análise, forneça a predição.” Cada palavra gerada calibra a matriz de atenção para o próximo token, tornando o resultado final uma consequência matemática dos critérios que a própria máquina acabou de registrar.

5. Analogias clínicas para consolidação

• **Espaço latente e Temperatura ≈ Diagnóstico diferencial**
Caso vago = espaço latente gigante (ansiedade a feocromocitoma). Configurar o escopo do prompt é fechar o diferencial em um sistema de órgãos. Temperatura 0 é a conduta estrita do protocolo ACLS; temperatura elevada é hipótese criativa para caso raro sem diretriz clara.

• **Mecanismo de Atenção ≈ Semiologia e sinais de alerta**
O médico experiente ignora ruídos e foca em palavras-chave. Ao arquitetar o contexto, destacamos artificialmente quais “sinais clínicos” do texto a máquina deve correlacionar com maior peso.

• **Chain of Thought ≈ Evolução clínica raciocinada**
O médico não pula dos sintomas direto para a alta; evolui justificando a conduta (fisiopatologia → hipótese → conduta). Forçar a externalização impede a “alucinação” do desfecho.

6. Mensagem final para o pesquisador de saúde

Não confie na “benevolência” do modelo. Crie o relevo geométrico no qual a probabilidade só possa convergir para o resultado que a pesquisa exige.

O pesquisador de saúde do futuro não é aquele que sabe “fazer boas perguntas”, mas aquele que constrói ambientes matemáticos controlados — e, portanto, metodologicamente defensáveis — onde a Inteligência Artificial não tem margem para errar. Da mesma forma que um ensaio clínico bem desenhado não deixa margem para viés de seleção ou de aferição, o prompt bem arquitetado não deixa margem para alucinação estrutural ou factual.

Da súplica à engenharia: o uso responsável da IA em pesquisa e saúde começa pela compreensão de seus limites e pela capacidade de cercá-los com rigor.

7. Próximos passos sugeridos

- Laboratório prático com dados sintéticos de coortes clínicas.
- Exercícios de construção de prompts para imputação semântica de missing data.
- Geração de análises reprodutíveis a partir de bancos de dados hospitalares.
- Integração com pipelines de Extração-Transformação-Carga (ETL) e ferramentas de Explainable AI.

Material reestruturado para uso acadêmico — Faculdade de Medicina da UFMG.
Linguagem adaptada ao público médico de pós-graduação, com ênfase em rigor metodológico e aplicabilidade em pesquisa clínica.